Лабораторная работа №3: Реализация и оценка качества линейных и метрических моделей

1. Цель работы

Изучение принципов работы базовых алгоритмов классификации – логистической регрессии и метода k-ближайших соседей (k-NN). Освоение методики оценки качества моделей с помощью формальных метрик и анализа ошибок. Сравнительный анализ собственной реализации алгоритмов и инструментов библиотеки Scikit-learn.

Работа выполняется по вариантам.

2. Задание

Работа выполняется в два этапа в рамках единого Jupyter Notebook по вариантам:

> **Примечание по согласованию набора данных с Лабораторной работой №2**
>
> - **Основной регламент:** Номер варианта (1–30), алгоритм («ручная» реализация) и контрольные вопросы определяются по разделу «Варианты индивидуальных заданий» Лабораторной работы №3. Для выполнения рекомендуется использовать набор данных, указанный в строке Рекомендуемый датасет вашего варианта.
> - **Преемственность данных (сквозной проект):** Если в Лабораторной работе №2 вы исследовали задачу **бинарной или многоклассовой классификации** (например, отток клиентов, кредитный скоринг, ранняя диагностика заболеваний), допускается использовать ваш очищенный датасет из ЛР №2 по согласованию с преподавателем. При этом контрольные вопросы берутся из вашего номера варианта в ЛР №3.
> - **Случай регрессионного датасета в ЛР №2:** Если в ЛР №2 ваш вариант был ориентирован на регрессию (прогнозирование непрерывной величины – цены автомобиля, стоимости недвижимости, спроса на прокат и т. д.), для выполнения ЛР №3 необходимо взять профильный датасет классификации согласно вашему варианту ЛР №3 из таблицы ниже (либо перевести непрерывную величину в бинарные категории путем пороговой дискретизации по согласованию с преподавателем).

Этап I. «Ручная» реализация алгоритма и метрик:

- Реализовать на языке Python (без использования Scikit-learn) алгоритм классификации согласно варианту:
  - **Варианты 1, 3, 5... (нечетные):** Метод k-ближайших соседей (k-NN) с евклидовой метрикой.
  - **Варианты 2, 4, 6... (четные):** Логистическая регрессия (метод градиентного спуска для минимизации Cross-Entropy Loss).
- Реализовать функции для расчета матрицы ошибок (Confusion Matrix) и базовых метрик: **Accuracy, Precision, Recall, F1-score**.

Этап II. Использование библиотек и оценка качества:

- Выполнить разбиение выборки на обучающую (train) и тестовую (test) в пропорции 70/30 или 80/20 с использованием `train_test_split`.
- Обучить модели **LogisticRegression** и **KNeighborsClassifier** из библиотеки Scikit-learn.
- Сравнить результаты собственной реализации и библиотечной.
- Провести визуализацию матрицы ошибок и построить кривую обучения (Learning Curve) или кривую ROC-AUC (по возможности).

3. Содержание отчета

1. **Титульный раздел:** Название работы, сведения об авторе и варианте.
2. **Описание задачи:** Краткое описание решаемой задачи классификации (бинарная или многоклассовая).
3. **Программная реализация (Этап I):**
   - Листинг кода собственной реализации алгоритма.
   - Функции расчета метрик.
   - Тестовый запуск на небольшом фрагменте данных.
4. **Программная реализация (Этап II):**
   - Процесс обучения моделей Scikit-learn.
   - Таблица сравнения метрик (Accuracy, Precision, Recall, F1) для обеих моделей.
   - Визуализация Confusion Matrix (например, через `sns.heatmap`).
5. **Анализ результатов:** Обоснование того, какая модель лучше подходит для данной задачи (с учетом специфики предметной области).
6. **Ответы на вопросы к варианту:** Ответы на 5 контрольных вопросов.

4. Критерии оценивания

- Корректность математической логики в собственной реализации.
- Правильность интерпретации метрик (понимание разницы между Precision и Recall).
- Отсутствие переобучения (проверка метрик на тестовой выборке).
- Качество оформления визуализаций.

Рекомендации по выполнению

1. Выбор метрики

Помните, что **Accuracy** может быть обманчивой при дисбалансе классов (например, если 99% транзакций легитимны, модель, всегда предсказывающая «ок», будет иметь точность 99%, но пропустит все выбросы).

- Используйте **Recall**, если цена пропуска (ложноотрицательного результата) высока (например, диагностика болезни или утечка данных).
- Используйте **Precision**, если цена ложной тревоги (ложноположительного результата) высока (например, блокировка аккаунта или спам-фильтр).

2. Реализация k-NN (Stage I)

Алгоритм сводится к расчету расстояний от тестовой точки до всех обучающих, сортировке и выборе наиболее частого класса среди первых k соседей.

$$d(x, y) = \sqrt{\sum (x_i - y_i)^2}$$

3. Реализация Логистической регрессии (Stage I)

Основная задача – обновление весов w по формуле градиентного спуска:

$$w = w - \alpha \cdot \nabla J(w)$$

где α – скорость обучения (learning rate), а функция активации – сигмоида:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Пример реализации метрик (для Этапа I)

```
def get_metrics(y_true, y_pred):
    tp = sum((y_t == 1 and y_p == 1) for y_t, y_p in zip(y_true, y_pred))
    tn = sum((y_t == 0 and y_p == 0) for y_t, y_p in zip(y_true, y_pred))
    fp = sum((y_t == 0 and y_p == 1) for y_t, y_p in zip(y_true, y_pred))
    fn = sum((y_t == 1 and y_p == 0) for y_t, y_p in zip(y_true, y_pred))

    accuracy = (tp + tn) / len(y_true)
    precision = tp / (tp + fp) if (tp + fp) > 0 else 0
    recall = tp / (tp + fn) if (tp + fn) > 0 else 0
    f1 = 2 * (precision * recall) / (precision + recall) if (precision + recall) > 0
else 0

    return accuracy, precision, recall, f1
```

Для Лабораторной работы №3 «Реализация и оценка качества линейных и метрических моделей» к данным предъявляются требования, определяемые алгоритмами классификации (k-NN и логистическая регрессия).

Рекомендации по выбору исходных данных

1. Преемственность и подготовка (Data Heritage)

Лабораторная работа №3 – это практическое применение метрических и линейных моделей к признаковым пространствам классификации.

- **Выбор набора данных:** Базовым источником данных выступает набор, закрепленный за вашим вариантом в разделе «Варианты индивидуальных заданий». Если ваш датасет из ЛР №2 уже представлял задачу классификации, вы можете продолжить работу с ним в рамках сквозного проекта (по согласованию с преподавателем). Если в ЛР №2 исследовалась задача регрессии, используйте профильный датасет классификации из вашего варианта ЛР №3.

- **Качество выборки:** Если в процессе выполнения ЛР №2 вы обнаружили, что данных недостаточно или они зашумлены, скорректируйте пайплайн EDA перед обучением моделей.
- **Результат предобработки:** На вход алгоритмам Лабораторной №3 должны подаваться **только числа**. Убедитесь, что все категории закодированы (One-Hot/Label Encoding), а пропуски заполнены.
- **Масштабирование – критический фактор:**
  - Если у вас **k-NN (нечетные варианты)**, данные **обязательно** должны быть нормализованы (MinMaxScaler или StandardScaler). Без этого признаки с большими значениями (например, «Доход») полностью подавят признаки с малыми значениями (например, «Возраст»).
  - Для **логистической регрессии (четные варианты)** масштабирование ускоряет сходимость градиентного спуска.

2. Структура целевой переменной (Target)

Для Лабораторной №3 вам нужна задача **классификации**.

- **Бинарная классификация (рекомендуется):** Идеально, если целевой признак имеет два значения (0/1, True/False). Это упрощает расчет матрицы ошибок и интерпретацию метрик.
- **Многоклассовая классификация:** Если классов больше двух (например, 3 типа сетевых атак), вам придется либо адаптировать «ручную» реализацию (сделать её сложнее), либо перевести задачу в бинарную (например, «Атака типа А» против «Все остальные»).
- **Проблема дисбаланса:** Проверьте соотношение классов. Если один класс составляет 95% данных, метрика **Accuracy** будет всегда высокой, даже если модель не работает. В этом случае в отчете нужно сделать упор на **Precision** и **Recall**.

3. Разделимость данных (Separability)

Для линейных и метрических моделей важно, как классы «расположены» в пространстве признаков:

- **Линейная разделимость (для логистической регрессии):** Линейная регрессия пытается провести «прямую линию» (гиперплоскость) между классами. Если классы перемешаны как «соль с перецем», логистическая регрессия покажет низкие результаты.
- **Локальное сходство (для k-NN):** Алгоритм предполагает, что похожие объекты (с похожими признаками) находятся рядом. Если это не так (высокий уровень шума), k-NN будет ошибаться.

4. Что делать, если данные «слишком хорошие» или «слишком плохие»?

Иногда реальные датасеты из интернета оказываются либо слишком простыми (Accuracy 1.0 сразу), либо слишком зашумленными (Accuracy 0.5 – на уровне случайного гадания).

- **Если модель дает 100% точность:**
  - Проверьте, не оставили ли вы в признаках «утечку данных» (Data Leakage) – признаки, которые напрямую коррелируют с ответом (например, колонка «Причина смерти» в задаче предсказания выживаемости).
  - Попробуйте удалить самые сильные признаки, чтобы усложнить задачу модели.
- **Если модель дает слишком низкую точность:**

- Попробуйте отобрать только наиболее коррелирующие с целью признаки (используйте Heatmap из Лаб. №2).
- Для k-NN попробуйте изменить количество соседей (k).

5. Рекомендации по генерации данных (если требуется замена)

Если вы решили сменить данные специально под классификацию, при генерации через `sklearn.datasets.make_classification` используйте следующие параметры:

```
from sklearn.datasets import make_classification

X, y = make_classification(
    n_samples=1000,
    n_features=10,
    n_informative=5,     # количество реально полезных признаков
    n_redundant=2,       # избыточные признаки (коррелируют с полезными)
    n_clusters_per_class=1,
    flip_y=0.01,         # 1% шума (неверных меток) для реалистичности
    class_sep=1.0,       # степень разделимости классов (чем выше, тем проще)
    random_state=42
)
```

Проверка готовности данных к Лабораторной №3:

1. Целевая переменная – категориальная (метки классов).
2. Все признаки в `X` – числовые (после кодирования).
3. Признаки имеют сопоставимый масштаб (после нормализации).
4. Вы понимаете, какая ошибка в вашей задаче критичнее: «ложная тревога» (FP) или «пропуск события» (FN). Это определит ваш выбор между Precision и Recall.

Варианты индивидуальных заданий

Вариант №1. Классификация сетевого трафика (Intrusion Detection)

Контекст: Определение того, является ли сетевой пакет частью нормального трафика или признаком атаки (Anomaly/Normal).
Данные: `duration`, `protocol_type`, `src_bytes`, `dst_bytes`, `count` (число соединений к тому же хосту).
Рекомендуемый датасет: NSL-KDD Network Intrusion Detection Dataset (Kaggle)

Вопросы для оценки понимания (Вариант 1):

1. Почему в задаче обнаружения вторжений Recall важнее, чем Precision?
2. Как нормализация данных (MinMaxScaler) влияет на работу алгоритма k-NN в этой задаче?
3. Что произойдет с k-NN, если параметр k будет равен 1? А если он будет равен общему количеству записей в базе?
4. Как интерпретировать «ложноположительное» срабатывание (False Positive) в контексте сетевой безопасности?

5. Каким образом алгоритм k-NN справляется с нелинейно разделимыми данными по сравнению с простой линейной регрессией?

Вариант №2. Прогноз кредитного дефолта (Credit Scoring)

Контекст: Оценка вероятности того, что заемщик не вернет кредит (Default/Non-default).
Данные: `Age`, `AnnualIncome`, `CreditScore`, `LoanAmount`, `EmploymentDuration`.
Рекомендуемый датасет: Credit Risk Dataset (Kaggle)

Вопросы для оценки понимания (Вариант 2):

1. В чем заключается физический смысл коэффициентов (весов) в логистической регрессии?
2. Как изменится Confusion Matrix, если мы сместим порог отсечения (threshold) сигмоиды с 0.5 до 0.8?
3. Что такое L2-регуляризация и как она помогает логистической регрессии избежать переобучения на малых выборках?
4. Почему для оценки банковских рисков часто используют F1-меру вместо Accuracy?
5. Как логистическая регрессия обрабатывает выбросы в признаке `AnnualIncome` по сравнению с k-NN?

Вариант №3. Ранняя диагностика хронических заболеваний

Контекст: Бинарная классификация медицинских показателей для выявления риска развития заболевания (например, диабета).
Алгоритм (Этап I): Метод k-ближайших соседей (k-NN).
Данные: `Glucose`, `BloodPressure`, `BMI`, `Age`, `Insulin`.
Рекомендуемый датасет: Diabetes Dataset (UCI)

Вопросы для оценки понимания (Вариант 3):

1. Каковы медицинские последствия ошибки типа False Negative (ложноотрицательный результат) в данной задаче?
2. Почему для алгоритма k-NN критически важно, чтобы признаки `Age` и `Insulin` были приведены к одному масштабу?
3. Как выбрать оптимальное значение k, чтобы избежать переобучения модели?
4. Можно ли использовать k-NN, если часть медицинских данных представлена в виде категорий (например, "группа крови"), и как в этом случае считать расстояние?
5. Как изменится точность k-NN, если в выборке будет много «шумных» данных (пациентов с аномальными показателями)?

Вариант №4. Фильтрация спам-сообщений в корпоративной почте

Контекст: Анализ текстовых признаков письма для автоматического перемещения в папку «Спам».
Алгоритм (Этап I): Логистическая регрессия.
Данные: Частота слов-маркеров, наличие подозрительных ссылок, длина темы письма, количество вложений.
Рекомендуемый датасет: Spambase Dataset (UCI)

Вопросы для оценки понимания (Вариант 4):

1. Что важнее для спам-фильтра: высокая точность (Precision) или высокая полнота (Recall)? Обоснуйте с точки зрения пользователя.
2. Какую роль играет функция активации (сигмоида) в превращении линейного уравнения в вероятность принадлежности к классу «Спам»?
3. Как логистическая регрессия будет реагировать на появление в письме нового, ранее не встречавшегося слова-маркера?
4. Что такое «отступ» (margin) и как он связан с уверенностью модели в классификации письма?
5. Как наличие сильно коррелирующих признаков (например, количество ссылок и количество сокращенных ссылок) влияет на стабильность весов логистической регрессии?

Вариант №5. Прогноз оттока подписчиков онлайн-кинотеатра (Churn)

Контекст: Определение вероятности того, что пользователь отменит подписку в следующем месяце.
Алгоритм (Этап I): Метод k-ближайших соседей (k-NN).
Данные: `MonthlyHours` (время просмотра), `SupportTickets` (жалобы), `SubscriptionType`, `DaysSinceLastLogin`.
Рекомендуемый датасет: Telco Customer Churn (Kaggle)

Вопросы для оценки понимания (Вариант 5):

1. Как «проклятие размерности» влияет на эффективность k-NN при добавлении большого количества новых признаков о поведении пользователя?
2. Почему k-NN считается «ленивым» алгоритмом обучения?
3. Каким образом можно использовать веса соседей (расстояние до них), чтобы улучшить предсказание k-NN?
4. Если у пользователя 0 часов просмотра, но он не жаловался в поддержку, как k-NN определит его сходство с другими «молчунами»?
5. Как интерпретировать ситуацию, когда при $k = 3$ все три соседа принадлежат к разным классам (в случае многоклассовой классификации)?

Вариант №6. Обнаружение фродо-транзакций (Antifraud)

Контекст: Выявление подозрительных банковских операций, которые могут быть совершены злоумышленниками.
Алгоритм (Этап I): Логистическая регрессия.
Данные: `TransactionAmount`, `RegionDeviation` (отклонение от привычного региона), `TimeOfDay`, `MerchantCategory`.
Рекомендуемый датасет: Credit Card Fraud Detection (Kaggle)

Вопросы для оценки понимания (Вариант 6):

1. В задачах антифрода классы крайне несбалансированы (99.9% операций легитимны). Почему метрика Accuracy здесь абсолютно бесполезна?
2. Как с помощью изменения порога классификации (threshold) настроить систему на максимально жесткую фильтрацию транзакций?
3. Что произойдет с градиентным спуском, если установить слишком большой шаг обучения (learning rate) α?

4. Как логистическая регрессия позволяет оценить вклад каждого признака (например, суммы покупки) в вероятность мошенничества?
5. Почему регуляризация необходима при обучении модели на данных о транзакциях за короткий период времени?

Вариант №7. Анализ тональности отзывов на мобильное приложение

Контекст: Классификация текстовых отзывов пользователей на «положительные» и «отрицательные».
Алгоритм (Этап I): Метод k-ближайших соседей (k-NN).
Данные: Векторные представления слов (TF-IDF или Bag-of-Words), длина отзыва, наличие восклицательных знаков.
Рекомендуемый датасет: Google Play Store Apps and Reviews (Kaggle)

Вопросы для оценки понимания (Вариант 7):

1. Какую метрику расстояния (помимо Евклидовой) целесообразно использовать для сравнения векторов текстовых данных?
2. Как k-NN справится с короткими саркастичными отзывами (например, «Великолепно, приложение зависло сразу»)?
3. Какое влияние на поиск соседей окажет удаление «стоп-слов» (предлогов и союзов) из данных?
4. Почему при использовании k-NN для текстов часто наблюдается высокая вычислительная сложность на этапе предсказания?
5. Как визуализировать границы решения (decision boundaries) k-NN, если признаков в модели больше трех?

Вариант №8. Прогнозирование поступления абитуриента в университет

Контекст: Оценка шансов зачисления в вуз на основе результатов экзаменов и рейтинга школы.
Алгоритм (Этап I): Логистическая регрессия.
Данные: `GRE_Score`, `TOEFL_Score`, `University_Rating`, `SOP` (сила мотивационного письма), `CGPA` (средний балл).
Рекомендуемый датасет: Graduate Admission 2 (Kaggle)

Вопросы для оценки понимания (Вариант 8):

1. Как интерпретировать ситуацию, когда вес (коэффициент) при признаке `University_Rating` получился отрицательным?
2. Зачем в формулу логистической регрессии добавляется свободный член (bias/intercept)?
3. Каким образом сигмоида ограничивает выходные значения модели диапазоном [0, 1]?
4. Если `CGPA` измеряется по 10-балльной шкале, а `GRE` по 340-балльной, как это скажется на скорости сходимости градиентного спуска?
5. В каких случаях модель может выдать вероятность ровно 0.5 и как принять решение о классификации в этом случае?

Вариант №9. Классификация типов лесного покрова (Ecology)

Контекст: Определение типа леса на основе топографических и картографических данных.
Алгоритм (Этап I): Метод k-ближайших соседей (k-NN).
Данные: `Elevation` (высота над уровнем моря), `Aspect` (экспозиция склона), `Slope` (уклон), `Distance_To_Hydrology`, `Soil_Type`.
Рекомендуемый датасет: Covertype Dataset (UCI)

Вопросы для оценки понимания (Вариант 9):

1. Признак `Aspect` измеряется в градусах (0-360). Почему классическая Евклидова метрика может некорректно работать со значениями 1° и 359°?
2. Как построение диаграммы Вороного помогает визуализировать работу алгоритма k-NN на плоскости?
3. Что произойдет с точностью модели, если из данных удалить наиболее значимый признак (например, высоту над уровнем моря)?
4. Почему k-NN чувствителен к наличию неинформативных (мусорных) признаков в векторе данных?
5. Как изменится время классификации одного нового объекта при увеличении обучающей выборки в 10 раз?

Вариант №10. Оценка эффективности телемаркетинга банка

Контекст: Прогноз того, согласится ли клиент открыть депозит после телефонного звонка.
Алгоритм (Этап I): Логистическая регрессия.
Данные: `Age`, `Job_Type`, `Education`, `Default` (наличие просрочек), `Duration` (длительность последнего звонка).
Рекомендуемый датасет: Bank Marketing Dataset (UCI)

Вопросы для оценки понимания (Вариант 10):

1. Почему длительность звонка (`Duration`) часто является самым сильным признаком, но его опасно использовать для прогнозирования будущих кампаний?
2. Как функция потерь Log-Loss наказывает модель за уверенное, но неверное предсказание (например, предсказал 0.9, а по факту 0)?
3. Как обработать категориальный признак `Education` (Primary, Secondary, Tertiary) для использования в логистической регрессии?
4. В чем преимущество логистической регрессии перед k-NN с точки зрения интерпретируемости результатов для бизнеса?
5. Что такое «отношение шансов» (odds ratio) и как оно вычисляется на основе коэффициентов модели?

Вариант №11. Определение категории качества вина (Basic vs Premium)

Контекст: Автоматическая классификация вин на «обычные» и «элитные» по их химическому составу.
Алгоритм (Этап I): Метод k-ближайших соседей (k-NN).
Данные: `Fixed_Acidity`, `Volatile_Acidity`, `Residual_Sugar`, `Chlorides`, `Alcohol`.
Рекомендуемый датасет: Wine Quality Dataset (UCI)

Вопросы для оценки понимания (Вариант 11):

1. Влияет ли порядок признаков в векторе данных на результат работы алгоритма k-NN?
2. Каким образом можно реализовать k-NN для многоклассовой классификации (если категорий качества не 2, а 5)?
3. Если один и тот же объект встречается в обучающей выборке дважды, как это повлияет на поиск ближайших соседей?
4. Как ведет себя k-NN при наличии выбросов (например, вино с аномально высоким содержанием сахара из-за ошибки датчика)?
5. Опишите случай, когда увеличение k (количества соседей) приводит к упрощению разделяющей границы между классами.

Вариант №12. Прогноз конверсии посетителей интернет-магазина

Контекст: Определение вероятности того, что сессия пользователя завершится покупкой.
Алгоритм (Этап I): Логистическая регрессия.
Данные: `Administrative_Duration` (время в ЛК), `Informational_Duration`, `ProductRelated_Duration`, `BounceRates`, `SpecialDay` (близость к праздникам).
Рекомендуемый датасет: Online Shoppers Purchasing Intention Dataset (UCI)

Вопросы для оценки понимания (Вариант 12):

1. Как логистическая регрессия справляется с ситуацией, когда классы сильно разделены (между ними «пустое» пространство)?
2. Почему для этой задачи важно анализировать не только Accuracy, но и Precision (чтобы не предлагать скидки тем, кто и так купит)?
3. Что такое мультиколлинеарность и почему высокая зависимость между временем на разных страницах может мешать обучению модели?
4. Как регуляризация (L1/L2) помогает модели игнорировать малозначимые признаки поведения пользователя?
5. Каким образом можно использовать логистическую регрессию для задач ранжирования (например, показать первыми тех, кто вероятнее всего совершит покупку)?

Вариант №13. Распознавание рукописных цифр (упрощенная задача)

Контекст: Классификация изображений цифр (например, 0 и 1) на основе интенсивности пикселей.
Алгоритм (Этап I): Метод k-ближайших соседей (k-NN).
Данные: Значения яркости 64 пикселей (сетка 8x8), переведенные в вектор.
Рекомендуемый датасет: Optical Recognition of Handwritten Digits (UCI)

Вопросы для оценки понимания (Вариант 13):

1. Почему Евклидово расстояние между изображениями («пиксель в пиксель») может плохо работать при небольшом сдвиге цифры в сторону?
2. Как вычислительная сложность предсказания k-NN зависит от размерности входных данных (количества пикселей)?
3. Как выбрать значение k в задаче распознавания образов, чтобы избежать влияния случайного шума на картинке?
4. Каким образом можно визуализировать работу k-NN для 64-мерных векторов пикселей?

5. Почему для задач распознавания образов важно, чтобы обучающая выборка содержала разные варианты написания одной и той же цифры?

Вариант №14. Классификация DDoS-атак по признакам сетевых потоков (SYN-Flood vs Normal)

Контекст: Сетевой анализатор пакетов периметра сети. Задача – классифицировать трафик на легитимный и атаку типа TCP SYN Flood в режиме близком к реальному времени.
Данные: `flow_duration`, `total_fwd_packets`, `syn_flag_count`, `fwd_pkt_len_mean`, `flow_iat_mean` (интервал между пакетами).
Рекомендуемый датасет: IDS Intrusion CSV / CIC-IDS (Kaggle)

Вопросы для оценки понимания (Вариант 14):

1. Почему в задаче отражения DDoS-атак критически важно минимизировать время инференса модели k-NN при больших объемах трафика?
2. Как дисбаланс классов во время начала атаки влияет на соотношение метрик Precision и Recall?
3. В чем преимущество логистической регрессии перед k-NN с точки зрения вычислительной сложности на этапе применения?
4. Каким образом интерпретируются веса обученной логистической регрессии для признака `syn_flag_count`?
5. Почему признак `flow_duration` требует предварительной нормализации при использовании евклидова расстояния?

Вариант №15. Прогнозирование успешности технологических стартапов (Startup Success Prediction)

Контекст: Венчурный фонд анализирует анкеты и финансовые показатели молодых IT-компаний для решения о выделении посевных инвестиций.
Данные: `funding_total_usd`, `funding_rounds_count`, `team_size`, `founders_experience_years`, `patents_count`.
Рекомендуемый датасет: Startup Success Prediction Dataset (Kaggle)

Вопросы для оценки понимания (Вариант 15):

1. Как выбор порога классификации в логистической регрессии позволяет инвестору регулировать уровень риска портфеля?
2. Почему при малом объеме выборки алгоритм k-NN может страдать от локальной разреженности данных?
3. Как метрика F1-score помогает оценить баланс между пропуском перспективных проектов и инвестированием в провальные?
4. В чем выражается геометрический смысл разделяющей гиперплоскости логистической регрессии в пространстве инвестиционных признаков?
5. Как масштабирование признака `funding_total_usd` влияет на расчет расстояний до ближайших соседей?

Вариант №16. Детекция вредоносных сценариев PowerShell по поведенческим характеристикам

Контекст: Модуль EDR (Endpoint Detection and Response) анализирует запуск скриптов в операционной системе для выявления вредоносной активности (Malicious vs Benign).
Данные: `script_length`, `entropy_score`, `encoded_command_flag`, `network_calls_count`, `suspicious_tokens_ratio`.
Рекомендуемый датасет: Malicious PowerShell Script Dataset – MPSD (GitHub)

Вопросы для оценки понимания (Вариант 16):

1. Как матрица ошибок (Confusion Matrix) иллюстрирует ущерб от блокировки легитимного системного скрипта администратора?
2. Какая метрика расстояния (Манхэттенская или Евклидова) менее чувствительна к экстремальным значениям энтропии в k-NN?
3. Почему логистическая регрессия с L2-регуляризацией более устойчива к мультиколлинеарности между длиной скрипта и числом токенов?
4. Каким образом сигмоидная функция преобразует линейную комбинацию признаков скрипта в апостериорную вероятность атаки?
5. Что означает ситуация, когда k-NN при $k = 3$ и $k = 15$ выдает противоположные результаты классификации одного и того же скрипта?

Вариант №17. Классификация сетевых пользователей по профилю привилегий (Insider Threat Detection)

Контекст: Система мониторинга внутренних угроз оценивает действия сотрудников для выявления аномалий авторизации и несанкционированного доступа.
Данные: `login_hour`, `failed_attempts_count`, `accessed_shares_count`, `transferred_bytes`, `privilege_elevation_flag`.
Рекомендуемый датасет: CERT Insider Threat Test Dataset (CMU KiltHub)

Вопросы для оценки понимания (Вариант 17):

1. Почему в сценариях выявления инсайдеров ошибка второго рода (False Negative – пропуск инсайдера) опаснее ошибки первого рода?
2. Как алгоритм k-NN определяет границы нормы поведения пользователя на основе его кластера коллег?
3. В чем состоит физический смысл коэффициентов логистической регрессии при анализе признака `privilege_elevation_flag`?
4. Как нестандартный график работы сотрудника (сменный график) может сместить разделяющую гиперплоскость модели?
5. Почему нормализация признака `transferred_bytes` (объем переданных данных) критична для метрических методов?

Вариант №18. Прогнозирование возврата покупок в интернет-магазине одежды

Контекст: Логистический сервис e-commerce платформы прогнозирует вероятность возврата заказанного товара клиентом для оптимизации складских запасов.
Данные: `item_price`, `discount_percent`, `customer_return_rate_history`, `is_first_order`, `items_in_order_count`.
Рекомендуемый датасет: Clothing Fit Dataset for Size Recommendation (Kaggle)

Вопросы для оценки понимания (Вариант 18):

1. Как сдвиг порога вероятности в логистической регрессии помогает минимизировать затраты на логистику возвратов?
2. Почему метрика Accuracy может вводить в заблуждение, если доля возвратов составляет менее 15% от всех покупок?
3. Как выбор значения гиперпараметра k в k-NN влияет на устойчивость модели к новым клиентам с нулевой историей покупок?
4. Каким образом стандартизация признака `discount_percent` предотвращает доминирование цены товара при вычислении евклидова расстояния?
5. Опишите разницу в интерпретации предсказания вероятности возврата логистической регрессией и k-NN.

Вариант №19. Диагностика неисправностей оборудования телеком-вышек по радиометрии

Контекст: Система автоматизированного мониторинга базовых станций сотовой связи классифицирует аппаратные сбои радиомодулей.
Данные: `vswr_ratio` (коэффициент стоячей волны), `power_output_dbm`, `temp_transceiver_c`, `rx_errors_rate`, `channel_busy_ratio`.
Рекомендуемый датасет: Machine Predictive Maintenance Classification (Kaggle)

Вопросы для оценки понимания (Вариант 19):

1. Какую роль играет метрика Recall при обнаружении аварийного перегрева приемопередатчика базовой станции?
2. Как метрический алгоритм k-NN строит границы принятия решений при наличии локальных нелинейных кластеров неисправностей?
3. Что показывает график Precision-Recall в сравнении с ROC-кривой при редких аппаратных сбоях?
4. Как линейная разделяющая поверхность логистической регрессии соотносится с физическими границами параметров ГОСТ/3GPP?
5. Как взвешивание соседей по обратному расстоянию (distance-weighted k-NN) повышает надежность классификации?

Вариант №20. Авторизация пользователей по динамике нажатия клавиш (Keystroke Dynamics)

Контекст: Биометрическая система непрерывной аутентификации подтверждает подлинность пользователя по ритму и стилю ввода текста.
Данные: `mean_hold_time` (длительность удержания клавиши), `mean_flight_time` (время перелета между клавишами), `typing_speed_wpm`, `error_correction_rate`, `flight_time_variance`.
Рекомендуемый датасет: MEU-Mobile KSD Keystroke Dynamics (UCI)

Вопросы для оценки понимания (Вариант 20):

1. Почему в поведенческой биометрии метрика Precision критически важна для предотвращения раздражения легитимного пользователя?
2. Как проклятие размерности влияет на точность алгоритма k-NN при добавлении десятков временных интервалов между парами букв?
3. Каким образом логистическая регрессия присваивает веса признакам индивидуального темпа печати?

4. Как повлияет усталость пользователя или смена клавиатуры на положение точки объекта в признаковом пространстве?
5. В чем преимущество масштабирования признаков `MinMaxScaler` перед стандартизацией при строгих границах таймингов удержания?

Вариант №21. Прогнозирование оттока корпоративных клиентов SaaS-платформы (B2B Churn)

Контекст: CRM-система B2B облачного сервиса прогнозирует риск непродления годовой лицензии корпоративным клиентом.
Данные: `license_utilization_ratio`, `support_tickets_high_prio`, `monthly_active_seats`, `contract_length_months`, `days_since_last_nps`.
Рекомендуемый датасет: Customer Churn Dataset (Kaggle)

Вопросы для оценки понимания (Вариант 21):

1. Как логистическая регрессия позволяет отделу клиентского успеха (Customer Success) выделить ключевой фактор риска оттока?
2. Почему в B2B-оттоке ложноотрицательное решение (упущенный отток крупного контракта) несет критический финансовый ущерб?
3. Как ведет себя алгоритм k-NN, если в обучающей выборке присутствуют клиенты принципиально разного масштаба бизнеса?
4. Каким образом расчет метрики ROC-AUC позволяет оценить способность модели ранжировать клиентов по степени риска?
5. Как регуляризация весов предотвращает чрезмерный перекос модели в сторону признака числа тикетов техподдержки?

Вариант №22. Оценка кредитоспособности микробизнеса по транзакционной активности

Контекст: Скоринговая модель банка оценивает вероятность дефолта индивидуального предпринимателя по движению средств на расчетном счете.
Данные: `monthly_turnover`, `tax_payment_ratio`, `counterparties_count`, `average_daily_balance`, `overdraft_usage_frequency`.
Рекомендуемый датасет: SBA Loan Default Prediction (Kaggle)

Вопросы для оценки понимания (Вариант 22):

1. Как нормализация данных защищает алгоритм k-NN от доминирования абсолютной величины оборота над коэффициентом уплаты налогов?
2. Что показывает матрица ошибок модели при консервативной политике выдачи займов банком?
3. Как геометрически интерпретируется разделяющая прямая между надежными и дефолтными заемщиками в плоскости «Оборот – Остаток»?
4. Почему при изменении экономической конъюнктуры веса логистической регрессии могут потребовать калибровки?
5. В каких ситуациях метрика F1-score дает более адекватную оценку качества модели, чем общая точность (Accuracy)?

Вариант №23. Детектирование отказов облачных контейнеров по системным метрикам хоста

Контекст: Система оркестрации контейнеров прогнозирует сбой пода (Crash/OOM) за несколько минут до его возникновения.
Данные: `cpu_throttling_percentage`, `memory_rss_bytes`, `io_wait_time`, `network_dropped_packets`, `restart_count_last_24h`.
Рекомендуемый датасет: Google Cluster Data (GitHub)

Вопросы для оценки понимания (Вариант 23):

1. Почему при приближении к порогу исчерпания памяти (OOM) метрический метод k-NN может реагировать быстрее жестких порогов мониторинга?
2. Как интерпретировать вероятность сбоя, полученную на выходе сигмоидной функции логистической регрессии?
3. Какое влияние оказывает масштаб признака `memory_rss_bytes` (в байтах) на расчет евклидова расстояния без масштабирования?
4. Как использовать соотношение Precision и Recall для минимизации лишних перезапусков здоровых контейнеров?
5. Что означает переобучение модели k-NN при значении $k = 1$ в условиях зашумленных метрик загрузки процессора?

Вариант №24. Классификация поддельных отзывов на маркетплейсе (Fake Reviews Detection)

Контекст: Антифрод-система интернет-магазина выявляет заказные отзывы по поведенческим метрикам профиля автора.
Данные: `reviews_count_same_day`, `avg_review_rating`, `verified_purchase_flag`, `author_account_age_days`, `review_text_similarity_score`.
Рекомендуемый датасет: Fake Reviews Dataset (Kaggle)

Вопросы для оценки понимания (Вариант 24):

1. Как бинарный флаг `verified_purchase_flag` (подтвержденная покупка) влияет на смещение разделяющей поверхности логистической регрессии?
2. Почему в задаче фильтрации спама метрика Precision важнее Recall для предотвращения удаления честных негативных отзывов?
3. Как выбор метрики расстояния (Евклид против Манхэттена) в k-NN влияет на классификацию авторов с аномально высокой активностью?
4. Каким образом строится ROC-кривая при переборе порога классификации вероятности поддельного отзыва?
5. В чем состоит вычислительное ограничение k-NN при проверке миллионов ежедневных отзывов на платформе?

Вариант №25. Скоринг лидов в корпоративной CRM-системе (Lead Scoring)

Контекст: Модуль автоматизации продаж оценивает вероятность закрытия коммерческой сделки на основе истории коммуникаций.
Данные: `website_visits_count`, `email_open_rate`, `demo_request_flag`, `company_employee_count`, `time_on_pricing_page_sec`.
Рекомендуемый датасет: Lead Scoring Dataset (Kaggle)

Вопросы для оценки понимания (Вариант 25):

1. Как веса логистической регрессии позволяют менеджеру по продажам приоритизировать звонки наиболее «горячим» клиентам?
2. Почему признак `demo_request_flag` может иметь огромный вес и как это отражается на величине свободного члена (bias)?
3. Как k-NN группирует похожих потенциальных клиентов в кластеры по масштабу компании и цифровому интересу?
4. Каким образом несбалансированность классов (успешных сделок обычно 5-10%) искажает восприятие метрики Accuracy?
5. Как кросс-валидация помогает проверить обобщающую способность линейной модели при ограниченном числе ежемесячных сделок?

Вариант №26. Детектирование несанкционированного криптомайнинга (Cryptojacking Detection)

Контекст: Система мониторинга серверной инфраструктуры выявляет скрытую работу программ-майнеров по профилю загрузки ресурсов.
Данные: `cpu_utilization_mean`, `cpu_user_system_ratio`, `gpu_memory_usage`, `network_out_bytes_per_sec`, `thread_context_switches`.
Рекомендуемый датасет: Cryptomining Data Set (Kaggle)

Вопросы для оценки понимания (Вариант 26):

1. Почему алгоритм логистической регрессии предпочтителен для встроенного легковесного агента мониторинга хоста?
2. Как отличить легитимную научную компиляцию кода от криптомайнинга на основе метрик Precision и Recall?
3. Какое значение гиперпараметра k в k-NN обеспечит лучшую устойчивость к кратковременным пикам штатной вычислительной нагрузки?
4. Как нормализация данных предотвращает игнорирование признака переключения контекстов (`thread_context_switches`)?
5. Что означает положительный коэффициент логистической регрессии при признаке постоянной загрузки GPU?

Вариант №27. Классификация запросов к базе данных на предмет SQL-инъекций

Контекст: Web Application Firewall (WAF) выполняет статистический анализ входящих HTTP-параметров для предотвращения SQLi.
Данные: `query_length`, `special_characters_ratio`, `sql_keywords_count`, `whitespace_count`, `entropy_score`.
Рекомендуемый датасет: SQL Injection Dataset (Kaggle)

Вопросы для оценки понимания (Вариант 27):

1. Почему в системах защиты веб-приложений Recall (полнота обнаружения атак) является первоочередной метрикой?
2. Как логистическая регрессия вычисляет границу между сложным легитимным поисковым запросом и вредоносным пейлоадом?
3. В чем опасность использования алгоритма k-NN в режиме реального времени при пропускной способности шлюза в десятки тысяч RPS?

4. Как масштабирование признаков с помощью `StandardScaler` влияет на веса признаков в линейной модели?
5. Каким образом матрица ошибок позволяет рассчитать экономические последствия от ложной блокировки платежного запроса клиента?

Вариант №28. Прогнозирование риска срыва сроков поставки в логистической цепочке

Контекст: Платформа управления поставками оценивает вероятность задержки отгрузки партии комплектующих контрагентом.
Данные: `planned_lead_time_days`, `historical_delay_rate`, `order_volume_units`, `supplier_reliability_score`, `customs_clearance_required_flag`.
Рекомендуемый датасет: DataCo Smart Supply Chain for Big Data Analysis (Kaggle)

Вопросы для оценки понимания (Вариант 28):

1. Как выбор порога отсечения в логистической регрессии позволяет логисту заранее заказать экспресс-доставку у резервного поставщика?
2. Почему при вычислении расстояний в k-NN категориальный признак таможенного оформления требует осторожности?
3. Как метрика ROC-AUC помогает сравнить качество моделей логистической регрессии и k-NN на валидационной выборке?
4. В чем заключается эффект недообучения (Underfitting) линейной модели при сложной нелинейной зависимости сбоев от объема партии?
5. Как стандартизация признаков сглаживает разницу между днями поставки и рейтингом поставщика от 0 до 1?

Вариант №29. Классификация причин инцидентов доступности ИТ-сервисов (Hardware vs Software)

Контекст: Система мониторинга инцидентов дата-центра классифицирует источник аварии для автоматического назначения дежурной бригады.
Данные: `kernel_panic_count`, `smart_alerts_count`, `app_error_logs_rate`, `packet_loss_spike`, `system_uptime_hours`.
Рекомендуемый датасет: Incident Management Process Enriched Event Log (UCI)

Вопросы для оценки понимания (Вариант 29):

1. Как линейная граница логистической регрессии разделяет аппаратные поломки (диски, память) и программные дефекты (баги в сервисе)?
2. Почему в задаче маршрутизации инцидента важна сбалансированная точность по каждому классу (Macro-F1)?
3. Как алгоритм k-NN находит прецеденты аналогичных сбоев в истории эксплуатации серверного парка?
4. Каким образом стандартизация признака времени непрерывной работы (`uptime`) предотвращает подавление счетчиков ошибок ядра?
5. Что произойдет с качеством классификации k-NN, если два различных класса имеют сильно перекрывающиеся распределения признаков?

Вариант №30. Оценка вероятности клика по контекстному рекламному баннеру (CTR Prediction)

Контекст: Рекламный RTB-движок рассчитывает вероятность клика пользователя по баннеру для выставления оптимальной ставки на аукционе.
Данные: `banner_position`, `user_historical_ctr`, `device_category_mobile_flag`, `page_topic_match_score`, `time_of_day_hour`.
Рекомендуемый датасет: Click-Through Rate Prediction – Avazu (Kaggle)

Вопросы для оценки понимания (Вариант 30):

1. Почему в задачах предсказания кликов (CTR ~ 1-2%) метрика Accuracy полностью неприменима для оценки качества модели?
2. Как логарифмическая функция потерь (Log-Loss) штрафует уверенные неверные предсказания вероятности в логистической регрессии?
3. В чем заключается причина высокой скорости инференса логистической регрессии, критичной для аукционов реального времени (RTB < 50 мс)?
4. Как алгоритм k-NN страдает от высокой плотности объектов в пространстве признаков при миллионных объемах логов показов?
5. Каким образом PR-кривая (Precision-Recall) позволяет выбрать оптимальный рабочий диапазон ставок рекламодателя?